HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO MÔN HỌC
PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH

Assignment 07

Họ tên: Phan Văn Khôi
Mã sinh viên: B23DCCN447
Lớp: D23CTPM01-B
Giảng viên PGS. TS. Trần Đình Quế

Hà Nội – 2026

Mục Lục

Thông Tin Project **1**

1 Cơ Sở Lý Thuyết Về Knowledge Graph Và RAG **2**
1.1 Lịch sử và vai trò . . . 2
1.2 Knowledge Graph và bộ ba tri thức . . . 2
1.3 Retrieval-Augmented Generation . . . 2
1.4 TF-IDF và độ tương đồng cosine . . . 3
1.5 Agent điều phối có kiểm soát . . . 3

2 Thiết Kế Hệ Thống Và Dữ Liệu **4**
2.1 Hai dataset và phạm vi hỏi đáp . . . 4
2.2 Schema graph và nguồn văn bản . . . 4
2.3 Chỉ mục, sinh câu trả lời và định tuyến . . . 5

3 Thực Nghiệm Trên Amazon Stock Price **6**
3.1 Khảo sát và phân bố dữ liệu . . . 6
3.2 Kết quả xây graph và chỉ mục RAG . . . 6
3.3 Câu hỏi kiểm chứng . . . 7

4 Thực Nghiệm Trên diabetes_large **8**
4.1 Khảo sát, nhãn và phân bố . . . 8
4.2 Kết quả xây graph và chỉ mục RAG . . . 8
4.3 Câu hỏi kiểm chứng . . . 9

5 Triển Khai Agent Trên Localhost **10**
5.1 CLI, web và API . . . 10
5.2 Giao diện Amazon: câu hỏi graph và RAG . . . 10
5.3 Giao diện diabetes_large: câu hỏi graph và RAG . . . 11

6 Đánh Giá, Giới Hạn Và Kết Luận **13**
6.1 Kiểm chứng khả năng tái lập . . . 13
6.2 Giới hạn và hướng phát triển . . . 13
6.3 Kết luận . . . 13

Danh Mục Hình

3.1 EDA Amazon Stock Price xuất từ output notebook Assignment 07 6

4.1 EDA diabetes_large xuất từ output notebook Assignment 07 8

5.1 Giao diện Amazon trả lời câu hỏi Close ngày 05/12/2023 bằng Knowledge Graph 11
5.2 Giao diện Amazon trả lời câu hỏi tóm tắt bằng RAG và Qwen3 11
5.3 Giao diện diabetes trả lời tỷ lệ nhãn 1 ở nữ bằng Knowledge Graph 12
5.4 Giao diện diabetes trả lời câu hỏi tóm tắt bằng RAG và Qwen3 12

Danh Mục Bảng

2.1 Tổng quan hai CSV gốc 4
2.2 Biểu diễn KG và corpus RAG của hai bài toán 4
2.3 Cấu hình thực tế trong hai file deploy 5

3.1 Đầu ra agent Amazon đã lưu trong notebook 7

4.1 Đầu ra agent diabetes_large đã lưu trong notebook 9

Thông Tin Project

GitHub project: https://github.com/KhoiF/PTHTTM

Báo cáo này tổng hợp hai notebook và hai ứng dụng cục bộ của Assignment 07:

- **Amazon Stock Price:** `amazon_kb_rag_agent.ipynb` và `deploy.py`;
- **diabetes_large:** `diabetes_kb_rag_agent.ipynb` và `deploy.py`.

Hai notebook thực hiện khảo sát dữ liệu, xây Knowledge Graph (KG), lập chỉ mục Retrieval-Augmented Generation (RAG), rồi kiểm tra agent. Hai file deploy cung cấp giao diện dòng lệnh và web Flask trên localhost. Các số liệu, hình EDA và câu trả lời minh họa dưới đây được lấy từ output đã lưu của notebook.

Chương 1

Cơ Sở Lý Thuyết Về Knowledge Graph Và RAG

1.1 Lịch sử và vai trò

Các hệ cơ sở tri thức biểu diễn sự kiện bằng thực thể và quan hệ đã được nghiên cứu trước thời đại large language model. Semantic Web phát triển các chuẩn để mô tả và liên kết tài nguyên bằng dữ liệu có cấu trúc. Năm 2012, Google giới thiệu Knowledge Graph trong tìm kiếm nhằm xử lý thực thể cùng quan hệ của chúng thay vì chỉ khớp chuỗi ký tự [1]. Năm 2020, Lewis và cộng sự giới thiệu Retrieval-Augmented Generation, kết hợp truy xuất nguồn tri thức với mô hình sinh văn bản [2].

Trong bài tập này, KG đóng vai trò một knowledge base (KB) có thể truy vấn theo khóa và quan hệ. RAG biến dữ liệu thành các đoạn văn có nguồn, tìm đoạn liên quan đến câu hỏi và cung cấp chúng cho mô hình ngôn ngữ. Agent chọn công cụ phù hợp với câu hỏi và trả kèm nguồn, giúp người đọc kiểm tra được dữ kiện.

1.2 Knowledge Graph và bộ ba tri thức

Một KG có thể mô tả bằng $G = (V, E)$, trong đó V là tập nút và $E \subseteq V \times R \times V$ là tập cạnh có nhãn quan hệ thuộc R. Bộ ba (s, p, o) gồm chủ thể, quan hệ và đối tượng. Ví dụ:

$$(\texttt{year:2023},\ \texttt{has_month},\ \texttt{month:2023-12}). \tag{1.1}$$

Mỗi node còn có thuộc tính số hoặc văn bản. Chẳng hạn, node phiên AMZN ngày 05/12/2023 lưu `Close = 146.880005`, còn node nhóm giới tính nữ của diabetes lưu số bản ghi, số nhãn 1 và tỷ lệ. Graph được cài bằng `networkx.DiGraph`. Khóa node ổn định và tên quan hệ tường minh giúp tránh nhập nhằng khi truy vấn.

Quy trình tạo KB gồm kiểm tra schema CSV, chuẩn hóa khóa, xây node/cạnh, nạp thuộc tính và đối chiếu với phép tính trực tiếp trên CSV. KB chỉ phản ánh những sự kiện được đưa vào graph. Truy vấn một ngày không có phiên hoặc một nhóm không có trong CSV phải báo thiếu dữ liệu.

1.3 Retrieval-Augmented Generation

RAG gồm hai giai đoạn chính. Khi chuẩn bị dữ liệu, hệ thống chuyển CSV thành tài liệu ngắn có ID nguồn và lập chỉ mục. Khi nhận câu hỏi, hệ thống truy xuất tài liệu liên quan, đặt chúng vào prompt và yêu cầu mô hình sinh câu trả lời dựa trên ngữ cảnh đó:

$$\text{CSV} \to \text{Documents} \to \text{Index} \xrightarrow{\text{Question}} \text{Top-}k\text{ evidence} \to \text{LLM} \to \text{Answer + Sources}. \tag{1.2}$$

Hai ứng dụng dùng Qwen3-0.6B cục bộ cho bước sinh [3]. Model chỉ được nạp khi câu hỏi thật sự đi vào nhánh RAG và được giữ trong bộ nhớ cho các câu hỏi tiếp theo.

1.4 TF-IDF và độ tương đồng cosine

Notebook dùng `TfidfVectorizer` với `analyzer="char_wb"`, n-gram ký tự độ dài 3–5 để xử lý câu hỏi tiếng Việt xen tên cột tiếng Anh. TF-IDF tăng trọng số cho những cụm đặc trưng của tài liệu và giảm trọng số của cụm xuất hiện phổ biến. Với vector câu hỏi q và tài liệu d, điểm xếp hạng là:

$$\text{cosine}(q, d) = \frac{q \cdot d}{\|q\|_2 \|d\|_2}. \tag{1.3}$$

Hệ thống lấy nhiều nhất bốn tài liệu có điểm từ $0{,}10$. Ngưỡng này chỉ là điều kiện liên quan về mặt văn bản; nó không bảo đảm nội dung được truy xuất đủ để trả lời mọi câu hỏi. Nếu không có tài liệu đạt ngưỡng, agent thông báo thiếu bằng chứng.

1.5 Agent điều phối có kiểm soát

Agent áp dụng quy tắc từ trên xuống: phát hiện khóa ngày hoặc nhóm để tra graph, dùng CSV cho phép tính tổng hợp, và dùng RAG cho câu hỏi mô tả. Các giá trị thống kê được tạo bằng phép tính trên dữ liệu hoặc thuộc tính graph; LLM diễn đạt tài liệu truy xuất. Đầu ra gồm ba trường `answer`, `sources` và `tools`. Trường `tools` cho biết nhánh thực sự đã chạy, ví dụ `knowledge_graph` hoặc cặp `rag_retrieval`, `local_llm`.

Chương 2

Thiết Kế Hệ Thống Và Dữ Liệu

2.1 Hai dataset và phạm vi hỏi đáp

Bảng 2.1: Tổng quan hai CSV gốc

Dataset	Bản ghi	Cột CSV	Thông tin chính
Amazon Stock Price	6.684	7	Date, OHLC, Adj Close, Volume; lịch sử 15/05/1997–05/12/2023
diabetes_large	100.000	9	Đặc điểm nhân khẩu, chỉ số và nhãn `diabetes` nhị phân

File Amazon được đọc theo ngày và sắp tăng dần. File diabetes có chín cột gốc; hàm nạp tạo thêm `age_group` theo bốn khoảng 0–17, 18–39, 40–59 và 60 tuổi trở lên. Vì vậy DataFrame sau xử lý có mười cột. Các khoảng tuổi chỉ dùng để mô tả dữ liệu, không phải ngưỡng y khoa.

2.2 Schema graph và nguồn văn bản

Bảng 2.2: Biểu diễn KG và corpus RAG của hai bài toán

	Amazon Stock Price	diabetes_large
Node	AMZN, năm, tháng, phiên giao dịch	Dataset, nhóm thống kê, kết quả nhãn 0/1
Quan hệ	`has_year`, `has_month`, `has_session`	`has_cohort`, `positive_count`, `negative_count`
Thuộc tính	OHLC, Adj Close, Volume của phiên	Số bản ghi, số nhãn 1, tỷ lệ của nhóm
Tài liệu RAG	Tổng quan, một tài liệu mỗi phiên, một tài liệu mỗi tháng	Tổng quan và một tài liệu mỗi nhóm

Không tạo node theo từng người bệnh trong diabetes. Điều này giữ KG ở mức thống kê, phù hợp với câu hỏi tổng hợp và tránh suy diễn rằng hai bản ghi có đặc điểm giống nhau là cùng một cá nhân. Mỗi tài liệu có ID cố định như `AMZN:2023-12-05`, `AMZN:month:2023-12` hoặc `DIABETES:gender:Female`.

2.3 Chỉ mục, sinh câu trả lời và định tuyến

Bảng 2.3: Cấu hình thực tế trong hai file deploy

Thành phần	**Cấu hình**
Graph	`networkx.DiGraph`, tạo khi khởi tạo agent
Chỉ mục	TF-IDF ký tự, n-gram 3–5; ma trận sparse trong bộ nhớ
Truy xuất	Cosine similarity; tối đa 4 tài liệu, điểm tối thiểu 0,10
Mô hình sinh	`Qwen/Qwen3-0.6B`; tối đa 180 token mới; không bật thinking mode
Deploy	Flask bind `127.0.0.1`; CLI và `POST /api/chat`

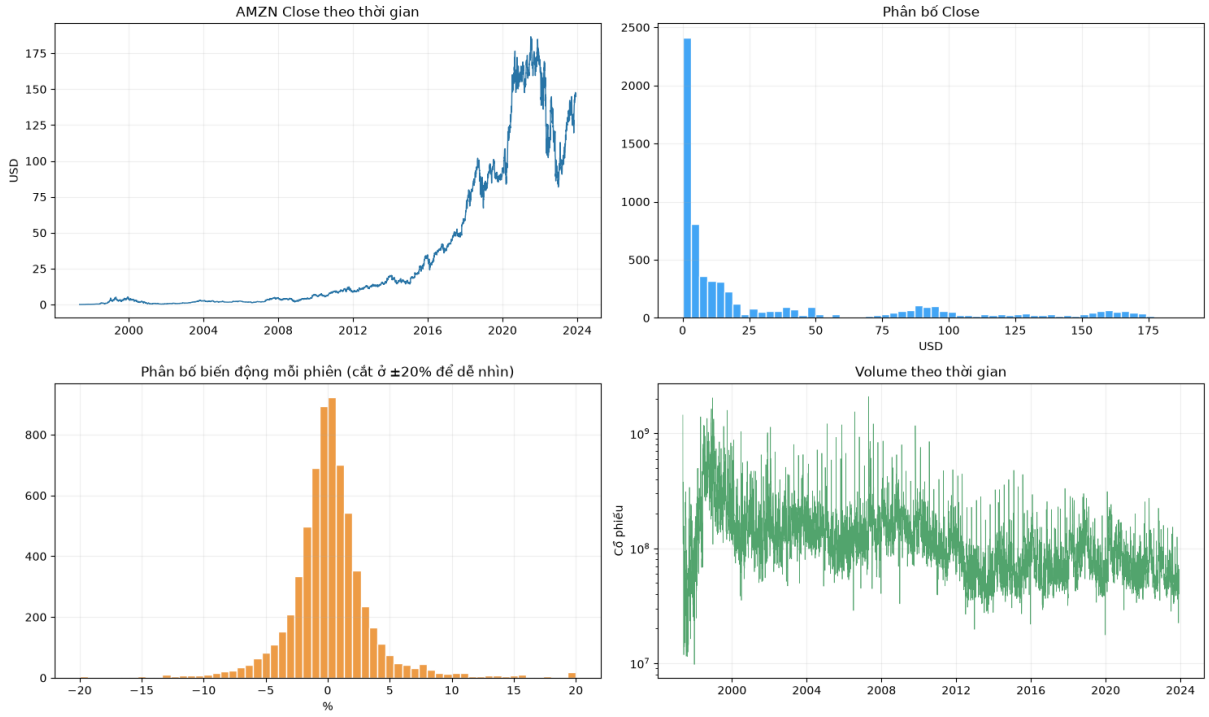
Amazon ưu tiên câu hỏi có hai ngày, một ngày, tháng, năm hoặc "mới nhất" để tra graph/CSV. diabetes ưu tiên từ chối yêu cầu chẩn đoán, liệt kê schema và trả thống kê theo nhóm hoặc toàn bộ dataset. Câu hỏi mô tả mới đi vào RAG. Prompt yêu cầu Qwen3 trả lời bằng tiếng Việt và chỉ dùng ngữ cảnh truy xuất; giao diện luôn hiển thị ID nguồn bên cạnh câu trả lời.

Chương 3

Thực Nghiệm Trên Amazon Stock Price

3.1 Khảo sát và phân bố dữ liệu

Notebook đọc 6.684 phiên từ 15/05/1997 đến 05/12/2023, không có ngày giao dịch trùng hoặc giá trị thiếu ở các cột bắt buộc. Bốn ô trong Hình 3.1 lần lượt thể hiện diễn biến Close, histogram Close, phân bố phần trăm thay đổi mỗi phiên và Volume theo thời gian. Phân bố biến động được cắt hiển thị tại $\pm 20\%$ để phần trung tâm dễ quan sát; dữ liệu gốc không bị cắt khi xây KB.



Hình 3.1: EDA Amazon Stock Price xuất từ output notebook Assignment 07

Giá theo thời gian có xu hướng và phạm vi thay đổi lớn. Vì thế, histogram gộp toàn bộ giai đoạn chỉ mô tả tập quan sát lịch sử, không phải phân phối giá cố định cho các năm tiếp theo.

3.2 Kết quả xây graph và chỉ mục RAG

KG Amazon có **7.032 node** và **7.031 cạnh**. Một đường đi mẫu nối AMZN đến nút năm 1997, nút tháng 05/1997, rồi đến phiên ngày 15/05/1997. Truy vấn node ngày 05/12/2023 cho `Close`

= 146.880005; đối chiếu với CSV trong notebook cho cùng giá trị, báo cáo làm tròn thành 146,88 USD.

Corpus có **7.005 tài liệu**; ma trận TF-IDF có kích thước 7.005×58.345. Với truy vấn về Amazon tháng 12/2023, tài liệu `AMZN:month:2023-12` được xếp đầu trong ví dụ notebook với điểm cosine $0{,}2643$. Các tài liệu lân cận có thể được trả thêm vì truy vấn mang nhiều cụm chung như "Amazon", "Close" và "Volume"; vì vậy cần đọc ID nguồn cùng nội dung.

3.3 Câu hỏi kiểm chứng

Bảng 3.1: Đầu ra agent Amazon đã lưu trong notebook

Câu hỏi	**Kết quả**	**Công cụ**
Close ngày 05/12/2023?	146,8800 USD; nguồn `AMZN:2023-12-05`	KG
Close từ 01 đến 05/12/2023?	3 phiên; trung bình 146,2500 USD; min 144,8400; max 147,0300 USD	CSV
Phiên cuối trong dữ liệu?	05/12/2023; Close 146,8800 USD	KG
Tóm tắt dữ liệu Amazon AMZN?	6.684 phiên từ 15/05/1997 đến 05/12/2023; nguồn `AMZN:overview`	RAG + LLM

Giá ở phiên cuối chỉ là giá cuối *trong CSV*; ứng dụng không truy cập giá thị trường hiện tại và không dự báo giá tương lai trong Assignment 07.

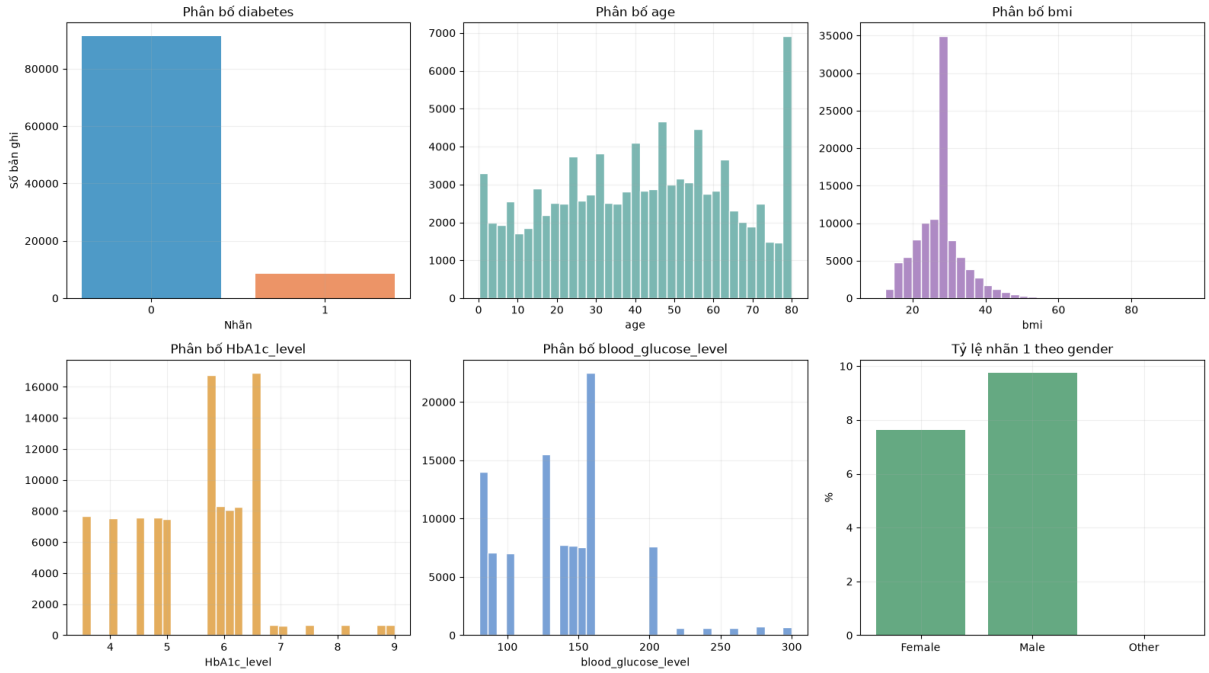
Chương 4

Thực Nghiệm Trên diabetes_large

4.1 Khảo sát, nhãn và phân bố

CSV có **100.000 bản ghi** và chín cột gốc. Notebook ghi nhận **3.854 dòng trùng toàn bộ thuộc tính**; các dòng này vẫn được giữ để thống kê phản ánh đúng tập dữ liệu cung cấp. Không có giá trị thiếu ở chín cột được dùng. Nhãn `diabetes=1` có 8.500 bản ghi, tương đương **8,50%**; nhãn 0 có 91.500 bản ghi.

Hình 4.1 cho thấy phân bố nhãn, tuổi, BMI, HbA1c, glucose và tỷ lệ nhãn 1 theo giới tính. Sự khác nhau giữa các nhóm là mô tả của dataset, không xác lập quan hệ nhân quả.



Hình 4.1: EDA diabetes_large xuất từ output notebook Assignment 07

4.2 Kết quả xây graph và chỉ mục RAG

KG gồm **20 node** và **51 cạnh**. Ví dụ node `cohort:gender:Female` nối từ node dataset, rồi nối đến hai node kết quả nhãn. Thuộc tính node cho biết 58.552 bản ghi nữ, 4.461 bản ghi nhãn 1 và tỷ lệ 7,62%. Notebook đối chiếu số lượng và số nhãn 1 với phép lọc trực tiếp từ CSV.

Corpus có **18 tài liệu**; ma trận TF-IDF có kích thước 18×1.351. Trong ví dụ truy xuất *"Tóm tắt diabetes gender Female"*, tài liệu `DIABETES:gender:Female` đứng đầu với điểm $0{,}4447$. Tài liệu nhóm Male và Other cũng xuất hiện trong top-k do có nhiều thuật ngữ chung; điểm truy xuất không được xem là tỷ lệ bệnh.

4.3 Câu hỏi kiểm chứng

Bảng 4.1: Đầu ra agent diabetes_large đã lưu trong notebook

Câu hỏi	**Kết quả**	**Công cụ**
Tỷ lệ diabetes ở nữ?	58.552 bản ghi, 4.461 nhãn 1, tỷ lệ 7,62%	KG
Tỷ lệ toàn dataset?	100.000 bản ghi, 8.500 nhãn 1, tỷ lệ 8,50%	CSV
Tỷ lệ nhóm 60+?	25.055 bản ghi, 4.932 nhãn 1, tỷ lệ 19,68%	KG
Tóm tắt diabetes_large?	100.000 bản ghi; 8.500 nhãn 1 và 91.500 nhãn 0; nguồn `DIABETES:overall`	RAG + LLM

Ứng dụng chỉ trình bày thống kê của tập quan sát. Đầu ra không dùng để chẩn đoán, ước lượng nguy cơ cá nhân hoặc quyết định điều trị.

Chương 5

Triển Khai Agent Trên Localhost

5.1 CLI, web và API

Mỗi `deploy.py` khởi tạo graph và chỉ mục khi agent được tạo. Chế độ CLI dùng `--question`; chế độ web dùng `--web`. Flask nhận `POST /api/chat` với JSON chứa trường `question` và trả về `answer`, `sources`, `tools`. Input rỗng hoặc sai kiểu được từ chối. Ứng dụng bind `127.0.0.1`; cổng mặc định là 8007 cho Amazon và 8008 cho diabetes.

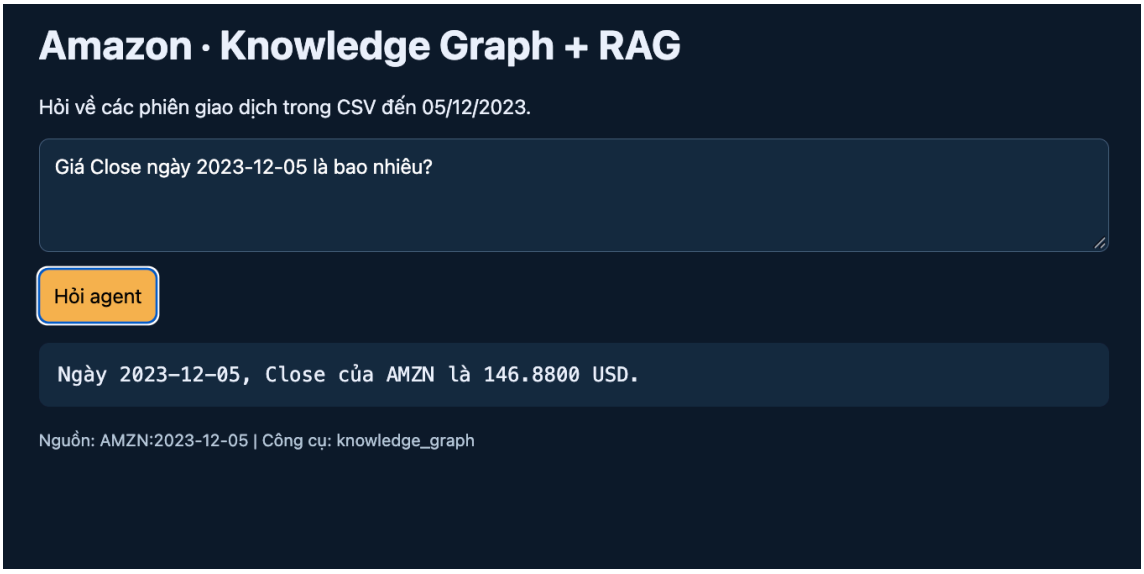
```
python "src/Assignment 07/Amazon Stock Price/deploy.py" --web --port 8007
python "src/Assignment 07/diabetes_large/deploy.py" --web --port 8008
```

Listing 5.1: Khoi dong hai giao dien web tu thu muc goc project

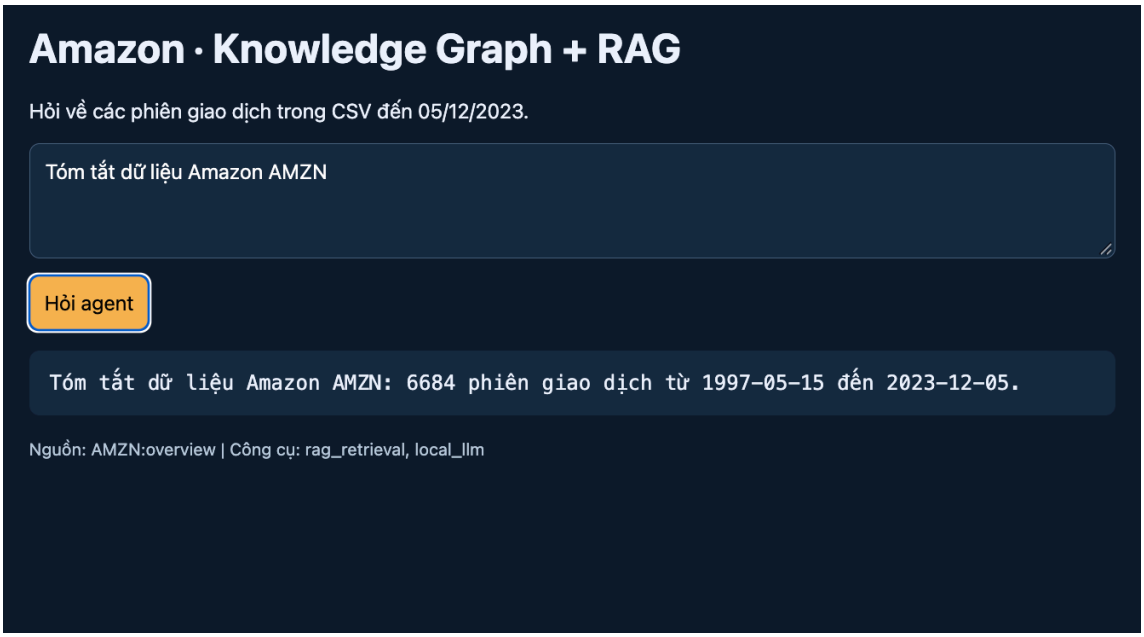
Mỗi lệnh cần chạy ở một terminal riêng. Mở `http://127.0.0.1:8007` hoặc `http://127.0.0.1:8008`, nhập câu hỏi rồi xem câu trả lời cùng nguồn và công cụ. Qwen3 được tải từ cache khi gặp câu hỏi đi vào nhánh RAG; lần tải model đầu tiên cần kết nối mạng. Các câu hỏi tra graph hoặc thống kê CSV không cần gọi LLM.

5.2 Giao diện Amazon: câu hỏi graph và RAG

Với câu hỏi về `Close` ngày 05/12/2023, agent dùng graph và hiển thị nguồn `AMZN:2023-12-05`. Câu hỏi tóm tắt dùng RAG, sau đó gọi LLM cục bộ. Đầu ra ghi hai công cụ `rag_retrieval` và `local_llm`. Nguồn là `AMZN:overview`.



Hình 5.1: Giao diện Amazon trả lời câu hỏi Close ngày 05/12/2023 bằng Knowledge Graph



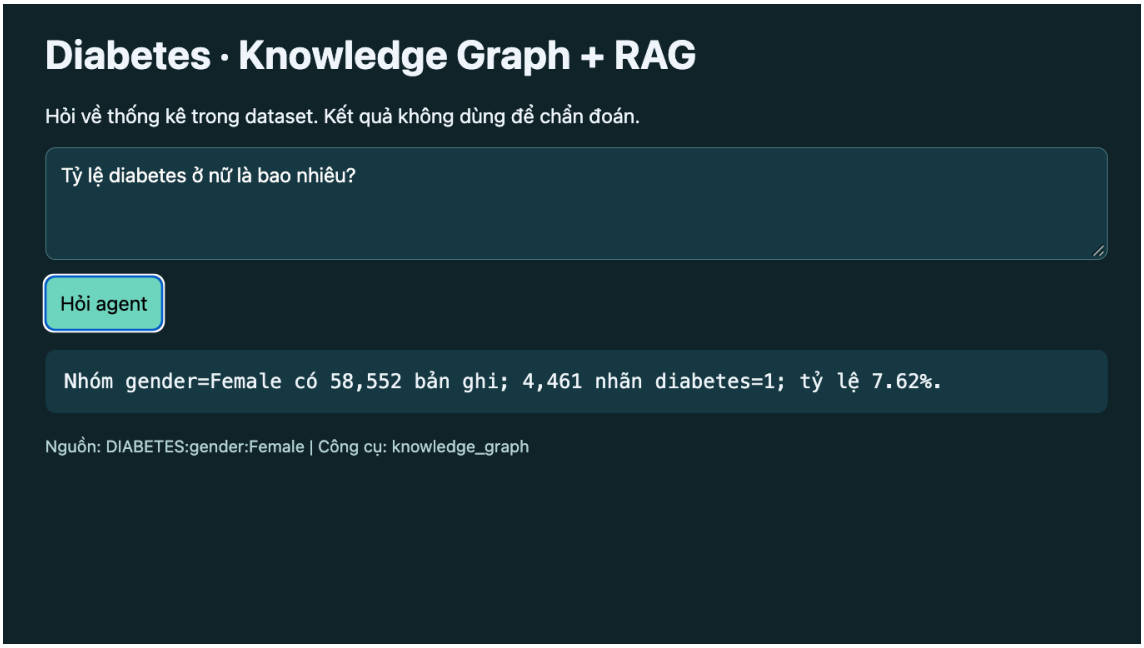
Hình 5.2: Giao diện Amazon trả lời câu hỏi tóm tắt bằng RAG và Qwen3

5.3 Giao diện diabetes_large: câu hỏi graph và RAG

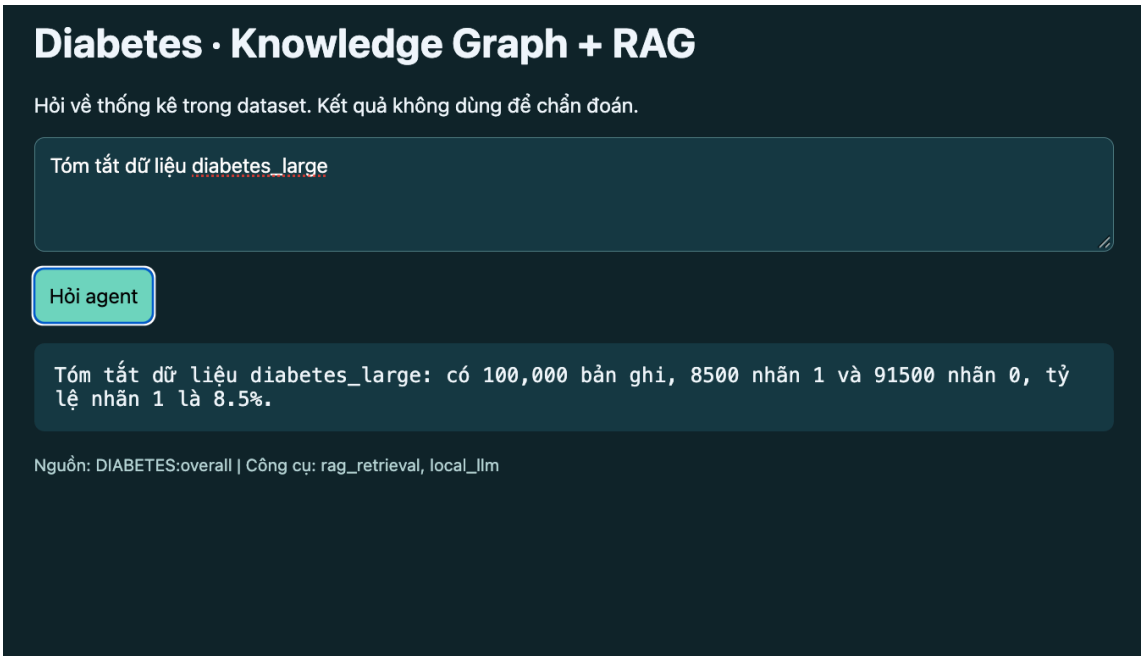
Với câu hỏi tỷ lệ nhãn 1 ở nữ, agent đọc node nhóm. ID nguồn được hiển thị là:

`DIABETES:gender:Female`

Với câu hỏi tóm tắt dataset, agent truy xuất tài liệu tổng quan `DIABETES:overall` và dùng Qwen3 để diễn đạt câu trả lời.



Hình 5.3: Giao diện diabetes trả lời tỷ lệ nhãn 1 ở nữ bằng Knowledge Graph



Hình 5.4: Giao diện diabetes trả lời câu hỏi tóm tắt bằng RAG và Qwen3

Chương 6

Đánh Giá, Giới Hạn Và Kết Luận

6.1 Kiểm chứng khả năng tái lập

Hai notebook đều có 21 cell và đã chạy hết các cell code, gồm cell `RUN_LOCAL_LLM=True`; output được lưu trong notebook, không có cell lỗi. Các câu hỏi kiểm chứng số liệu được đối chiếu với CSV. Kiểm tra API bao gồm trang web, payload hợp lệ, payload sai kiểu, ngày không có phiên, câu hỏi ngoài phạm vi và yêu cầu chẩn đoán. Trong các ví dụ RAG, đầu ra có `tools` chứa `rag_retrieval` và `local_llm`, cùng ID tài liệu nguồn.

6.2 Giới hạn và hướng phát triển

- TF-IDF ký tự dựa vào mức giống văn bản; truy vấn diễn đạt xa từ vựng corpus có thể không tìm được tài liệu phù hợp. Bài tập chưa có bộ câu hỏi gán nhãn để đo Recall@k hoặc groundedness một cách hệ thống.
- Qwen3-0.6B có thể rút gọn hoặc diễn đạt thiếu chi tiết. ID nguồn giúp kiểm tra lại, nhưng không tự chứng minh rằng mọi mệnh đề trong câu trả lời đều đúng.
- Giá Amazon dừng ở 05/12/2023. Dữ liệu diabetes là dữ liệu quan sát với nhãn mất cân bằng; tỷ lệ nhóm không phải quan hệ nhân quả hoặc công cụ chẩn đoán.
- Flask development server phục vụ demo localhost. Khi triển khai cho nhiều người dùng, cần bổ sung giới hạn request, quản lý tài nguyên model và cơ chế vận hành phù hợp.

6.3 Kết luận

Assignment 07 xây hai hệ hỏi đáp cục bộ trên dữ liệu bảng bằng cách kết hợp Knowledge Graph, thống kê CSV và RAG. Graph xử lý câu hỏi có khóa rõ ràng, phép tính trên CSV giữ độ chính xác cho câu hỏi số, còn RAG cung cấp ngữ cảnh có nguồn cho câu hỏi mô tả. Hai notebook và hai ứng dụng CLI/web cho thấy luồng từ khảo sát dữ liệu, biểu diễn tri thức, truy xuất đến trả lời bằng agent. Việc giữ nguồn và nêu giới hạn của từng dataset là điều kiện cần để sử dụng kết quả đúng mục đích.

Tài Liệu Tham Khảo

[1] Google Research, "New Challenges in Computer Science Research," 2012. https://research.google/blog/new-challenges-in-computer-science-research/.

[2] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," 2020. https://arxiv.org/abs/2005.11401.

[3] Qwen, "Qwen3-0.6B Model Card." https://huggingface.co/Qwen/Qwen3-0.6B.